

中国矿业大学
计算机科学与技术学院

2023 级本科生课程设计报告

课程名称 机器学习应用实践课程设计

设计题目 网络监督细粒度图像识别

开课学期 2025-2026 学年第 1 学期

报告时间 2025.12.31

学生姓名 刘润章，南怡波，徐瀚章

学 号

班 级 人工智能二班

专 业 人工智能

任课教师 杜文亮

《机器学习应用实践课程设计》课程报告评分表

开课学期:2025-2026 学年第 1 学期

姓名:徐瀚章

学号:

专业班级: 人工智能 24-06 班

姓名:刘润章

学号:

专业班级: 人工智能 23-02 班

姓名:南怡波

学号:

专业班级: 人工智能 23-02 班

序号	毕业要求	课程教学目标	考查方式与考查点	占比	得分
1	3.2	目标 4: 能够根据具体应用, 制定机器学习算法设计方案, 构建算法训练、验证、测试数据集, 并综合考虑机器学习算法模型和软硬件开发环境, 进行合理编程实现、程序测试及设计方案优化。	现场验收与答辩 考核机器学习算法的分析与选择的合理性、对已选用算法的理解能力, 编程实现的代码工作量、设计工作量等。	50%	
2	3.2	目标 5: 掌握程序设计报告撰写方法, 通过成果演示、陈述发言、清晰表达等方式进行有效沟通与交流。	现场验收与答辩 考核算法设计成果、所涉及的问题答辩。验收算法设计报告的结构合理性、内容和图表的正确性。验收设计报告排版的规范性。	50%	
总成绩				100%	

任课教师: 杜文亮

2025 年 12 月 31 日

网络监督细粒度图像识别

刘润章, 徐瀚章, 南怡波

摘要 细粒度图像识别是计算机视觉领域中的一项挑战性任务, 尤其在物体子类别的区分上, 类别间细微差异使得传统的图像分类方法面临较大的难度。网络监督细粒度图像识别 (Webly-Supervised Fine-Grained Image Classification) 通过利用网络爬取的图像数据, 避免了传统人工标注的高成本与偏差, 但同时也面临着标签噪声和数据质量问题。本项目旨在利用网络爬取的弱标注数据, 提出一种适用于噪声数据环境下的细粒度识别算法。

本研究基于 WebFG-400 和 WebiNat-5000 数据集, 提出了一种三阶段的算法框架: 数据清洗、特征提取和噪声筛选。首先, 通过 `l_clean_minimal.py` 脚本进行数据清洗, 剔除损坏图像、透明图像和分辨率过小的图像, 减少了数据中的噪声样本。接着, 使用基于 ImageNet 预训练的深度学习神经网络提取图像特征, 并通过相似度评分筛选出疑似噪声样本。最后, 在数据清洗和特征提取的基础上, 通过噪声筛选和自监督学习提升模型的鲁棒性。

在 WebFG-400 数据集上的实验结果表明, 我们的模型相比基准模型提高了 3.5% 的准确率, 从 65.8% 提高到 69.3%。在 WebiNat-5000 数据集上, 模型的准确率从 58.2% 提高至 60.9%, 提升幅度为 2.7%。这些结果表明, 我们的方法有效减少了标签噪声对模型训练的影响, 并在多个细粒度类别的识别中取得了显著提升。在 2025 年第七届全球校园人工智能算法精英大赛省级选拔赛中, 我们的项目获得了二等奖。

关键词 细粒度图像识别; 网络监督学习; 标签噪声; 数据清洗; 特征提取; 自监督学习; WebFG-400; WebiNat-5000; 模型鲁棒性; 算法挑战赛

Network-based Fine-Grained Image Recognition

XU Han-Zhang

Abstract Fine-grained image recognition is a challenging task in the field of computer vision, especially in distinguishing between subcategories of objects, where subtle differences between categories make traditional image classification methods quite difficult. Webly-supervised fine-grained image classification leverages images crawled from the web, avoiding the high cost and biases of traditional manual annotation, but it also faces issues with noisy labels and data quality. This project aims to utilize weakly labeled data collected from the web to propose a fine-grained recognition algorithm suitable for noisy data environments.

This study is based on the WebFG-400 and WebiNat-5000 datasets and proposes a three-stage algorithm framework: data cleaning, feature extraction, and noise filtering. First, the data is cleaned using the script `l_clean_minimal.py`, removing corrupted images, transparent images, and images with too low resolution, thereby reducing the number of noisy samples. Next, image features are extracted using a deep neural network pretrained on ImageNet, and suspected noisy samples are filtered out through similarity scoring. Finally, based on the cleaned data and extracted features, the model's robustness is enhanced through noise filtering and self-supervised learning.

Experimental results on the WebFG-400 dataset show that our model improved accuracy by 3.5% compared to the baseline, increasing from 65.8% to 69.3%. On the WebiNat-5000 dataset, the model's accuracy increased from 58.2% to 60.9%, an improvement of 2.7%. These results indicate that our method effectively reduces the impact of label noise on model training and achieves significant improvement in

recognizing multiple fine-grained categories. In the provincial selection of the 2025 7th Global Campus Artificial Intelligence Algorithm Elite Competition, our project won second prize.

Key words Fine-grained image recognition; network supervised learning; label noise; data cleaning; feature extraction; self-supervised learning; WebFG-400; WebiNat-5000; model robustness; algorithm challenges

1 引言

细粒度图像识别是计算机视觉领域中的一项重要任务,它旨在区分属于同一物种或类别的不同子类。与传统的图像分类任务不同,细粒度图像识别面临的挑战主要来自于子类之间的外观差异极小,导致模型在分类时易受到噪声和不一致数据的影响。例如,在犬类分类任务中,区分“哈士奇”和“阿拉斯加”这两类犬种,不仅需要高精度的视觉特征提取,还需要解决类内差异大、类间差异小的问题。由于这些挑战,细粒度图像识别通常需要更精细的标注以及更强大的模型能力。

传统的细粒度图像识别方法依赖于人工标注的数据集,这些数据集通常需要大量的标注工作和专家知识,因此具有较高的成本和较长的开发周期。然而,随着深度学习的发展,网络监督学习(Webly-Supervised Learning)作为一种无需人工标注数据的替代方法,得到了广泛关注。网络监督学习通过从互联网上爬取大量的图像和标签信息,构建大规模的训练数据集,减少了对高成本人工标注数据的依赖。

然而,基于网络爬取的图像和标签数据,往往存在以下几个问题:

1. 标签噪声:网络图像的标签可能并不完全准确。例如,某些图像可能被错误地归类为不同类别,或者标签描述可能与实际图像内容不完全匹配。
2. 数据偏差:网络爬取的图像在数量和类别分布上通常存在偏差,可能某些类别图像数量过多,而其他类别则显得稀缺。
3. 长尾分布:网络数据通常呈现长尾分布,大部分类别包含较少的样本,少数类别包含大量样本,这使得模型难以对长尾类别进行有效识别。

为了应对上述挑战,本项目采用了网络监督细粒度图像识别(Webly-Supervised Fine-Grained Image Classification)的方法,旨在解决噪声标

签和数据不均衡等问题。我们采用了来自南京理工大学公开的 WebFG-400 和 WebiNat-5000 两个数据集,这些数据集中的图像和标签均来源于网络爬取,包含了大量细粒度类别数据。

在比赛中,参与者需要在这类网络监督数据上训练细粒度图像分类模型。赛题的目标是开发一种有效的算法,通过优化数据处理、模型架构和训练策略,在网络监督的环境下实现高效的细粒度图像识别。赛题中的数据集包含了大量的噪声标签和不均衡的类别分布,这使得细粒度图像识别任务更具挑战性。如何在网络爬取的噪声数据环境下提高模型的准确性和鲁棒性,成为了本次比赛的关键问题之一。

本项目的工作通过以下几方面进行了探索:

1. 数据清洗:在模型训练前,我们首先对网络爬取的数据进行了清洗,剔除掉损坏、分辨率过小或者透明背景的图像,减少了明显的噪声。
2. 特征提取:采用预训练的深度学习模型(例如 ResNet、ConvNeXt 等)对图像进行特征提取,通过对比学习方法优化模型在细粒度类别上的表现。
3. 噪声样本筛选:我们设计了一种基于相似度的噪声样本筛选策略,根据类内样本的相似性评分,自动识别和删除与其他样本差异较大的噪声样本,从而提升模型在测试集上的泛化能力。
4. 自监督学习:结合自监督学习方法,进一步提高模型在小样本类别和长尾数据上的鲁棒性,从而有效提升整体性能。

通过以上策略,本项目不仅在比赛中获得了优异的成绩,还为网络监督细粒度图像识别任务提供了一种有效的解决方案,能够有效减少标签噪声对模型训练的影响,并显著提高模型的分类精度。

2 算法介绍

本项目的目标是基于网络监督的图像数据

集进行细粒度图像分类。为了应对网络数据中的标签噪声、类别间细微差异以及数据不平衡等挑战，我们设计了一个由三大阶段组成的算法框架：数据清洗、特征提取和噪声筛选。每个阶段的具体算法介绍如下：

1. 数据清洗

数据清洗是本项目中的第一步，主要任务是剔除网络图像数据集中那些无效或质量差的样本。这些无效样本可能会导致后续训练过程中出现错误，影响模型的性能。我们设计的清洗算法通过检查图像的基本属性来筛选掉低质量样本。数据清洗步骤包括：

文件大小过滤：若图像文件小于指定大小（例如 10KB），则认为其为损坏文件或无效图像，进行删除。

解码失败处理：对于无法解码的图像（如损坏的 JPEG 文件），通过‘PIL’库的异常捕获机制进行排除。

图像尺寸过滤：若图像的最短边小于预设阈值（如 64 像素），则被认为是无效图像，并被删除。

透明图像检测：对于透明度过高的 PNG 或 GIF 图像，若图像几乎全透明（透明像素比例低于预设阈值），则判定为无效图像进行删除。

该阶段的目标是通过这些基本规则过滤掉明显不符合要求的图像，从而减少数据中的噪声，确保后续特征提取和模型训练阶段的顺利进行。

2. 特征提取

特征提取阶段的主要目标是从清洗后的图像中提取高效的视觉特征，以便后续的噪声筛选和分类任务。我们使用了基于深度学习的卷积神经网络（CNN），特别是使用了预训练的 ImageNet 模型来提取图像的深度特征。

特征提取步骤包括：

图像预处理：在特征提取之前，我们对所有图像进行了标准化处理，包括调整图像大小（例如，调整短边为 256 像素）、中心裁剪为 224x224 像素，并将其转换为‘RGB’模式。

使用预训练的 CNN 模型：我们采用了基于‘Timm’库的预训练卷积神经网络（如 ResNet、ConvNeXt 等），通过加载预训练权重，利用其在 ImageNet 上的特征提取能力，从图像中提取深层

次的视觉特征。提取出的特征向量用于后续的噪声筛选步骤。

特征归一化：提取的特征向量经过 L2 归一化处理，使得不同特征的尺度一致，便于后续基于相似度的计算。

此阶段的输出是一个包含所有图像特征的特征矩阵（features.npy）以及与图像路径和类别标签对齐的索引文件（index.csv）。

3. 噪声筛选

由于网络数据中普遍存在标签噪声，如何筛选出噪声样本，并保留有效的训练数据，是本项目的关键挑战之一。在这个阶段，我们设计了一种基于相似度评分的噪声筛选策略，通过计算图像间的相似度来识别并移除那些疑似噪声样本。

噪声筛选步骤包括：

类内相似度计算：对每个类别内部的图像特征进行比较，计算每个图像与该类别中其他图像的相似度。相似度计算基于余弦相似度（Cosine Similarity）来度量图像之间的相似性。

两种相似度评分：

s1：类中心相似度：首先计算每个类别所有图像的特征均值作为该类别的“类中心”，然后计算每个图像与类中心的余弦相似度作为评分。相似度高的图像被认为更符合该类别的特征。

s2：类内 Top-K 相似度：对于每个图像，计算其与同类别内其他图像的 Top-K 相似度平均值。这样可以有效排除类内有较大差异的图像，保留那些与其他图像具有高相似度的样本。

综合评分：将 s1 和 s2 两种相似度结合，通过加权平均（例如，权重为 $\alpha=0.7$ ）得到最终的评分 S。如果某些图像的相似度评分低于设定的阈值，则将其标记为噪声样本。

样本删除与保留：根据评分结果，筛选出低评分（低相似度）的噪声样本，并将其从训练数据集中移除。同时，确保每个类别中至少保留一定数量的图像（例如，每个类别至少保留 30 张样本），避免删除过多数据导致训练不充分。

通过这种基于相似度的噪声筛选策略，我们能够有效去除掉那些标签不准确或类别特征不一致的样本，提升模型的泛化能力。

4. 模型训练与评估

在特征提取和噪声筛选的基础上，我们使用

ConvNeXt 等卷积神经网络进行模型训练。为了提升模型的鲁棒性和泛化能力,我们采用了数据增强技术(如随机裁剪、翻转等)和正则化技术(如 Dropout、数据扩增等)进行训练。

训练步骤包括:

模型架构: 我们使用 ConvNeXt 模型作为基础架构, 基于其在图像分类任务中的优秀表现, 在比赛数据集上进行微调。ConvNeXt 模型采用了深度卷积神经网络和多尺度卷积层, 能够有效提取图像的细粒度特征。

优化器与学习率调度: 我们使用 Adam 优化器进行模型优化, 并采用 Cosine Annealing 学习率调度策略, 使得学习率在训练过程中逐渐减少, 帮助模型更好地收敛。

模型评估: 使用准确率 (Accuracy) 作为主要评估指标, 在 WebFG-400 和 WebiNat-5000 数据集的测试集上进行模型评估。通过与基准模型进行对比, 验证了我们方法的有效性。

3 实验结果

本节展示了在 WebFG-400 和 WebiNat-5000 数据集上应用我们提出的算法进行细粒度图像识别任务的实验结果。我们在多个关键步骤中进行了实验, 以验证数据清洗、特征提取、噪声筛选等方法对模型性能的影响。实验结果表明, 我们的算法在噪声标签数据环境下仍能有效提高模型的准确性和鲁棒性。

1. 实验设置

1.1 数据集:

WebFG-400: 包含 43,087 张训练图像, 13,882 张测试图像, 分为 400 个细粒度类别。数据涵盖鸟类、飞机和汽车等类别。

WebiNat-5000: 包含 580,865 张训练图像, 100,000 张测试图像, 涉及 5000 个自然物种子类别, 包括植物、昆虫、爬行动物等。

1.2 评估指标: 准确率 (Accuracy) 是本次实验的主要评估指标。准确率计算公式为: $Accuracy = \frac{\text{预测正确的样本数}}{\text{总样本数}}$ 。

1.3 训练参数:

模型: 使用基于 ConvNeXt 的模型, 采用预训练的 ImageNet 权重, 并对数据集进行微调。

优化器: 使用 Adam 优化器, 学习率调度采用 Cosine Annealing 策略。

批次大小: 64, 训练时采用数据增强策略, 包括随机裁剪、翻转等。

2. WebFG-400 数据集实验结果

在 WebFG-400 数据集上, 我们的算法在准确率方面表现出色。以下是实验结果:

方法	准确率 (%)
基准模型 (ResNet-50)	65.8
我们的模型	69.3

提升分析: 相比基准 ResNet-50 模型, 我们的模型在 WebFG-400 数据集上的准确率提高了 3.5%, 从 65.8% 提升至 69.3%。这一提升主要得益于数据清洗阶段剔除了大量噪声样本, 特征提取阶段通过使用预训练模型提取了更具辨识度的图像特征, 而噪声筛选阶段则进一步优化了数据集的质量, 有效减少了标签噪声对模型训练的影响。

模型表现: 我们的模型在多个类别的识别中都取得了较为一致的提升, 特别是在鸟类和汽车类别中, 模型的表现较基准模型提高了 5% 以上。对于飞机类别, 尽管类别间差异较小, 但通过噪声筛选策略, 模型的泛化能力得到了增强。

3. WebiNat-5000 数据集实验结果

在 WebiNat-5000 数据集上, 我们的模型同样展现了显著的性能提升。以下是实验结果:

方法	准确率 (%)
基准模型 (ResNet-50)	58.2
我们的模型	60.9

提升分析: 在 WebiNat-5000 数据集上, 我们的模型的准确率从 58.2% 提升至 60.9%, 提升幅度为 2.7%。虽然该数据集的规模远大于 WebFG-400, 且标签噪声更为严重, 但通过高效的数据清洗和特征提取方法, 我们的模型仍能够有效克服这些问题, 提高了细粒度类别的分类精度。

模型表现: 在 WebiNat-5000 的实验中, 我们的模型尤其在分类细粒度物种 (如植物和昆虫) 时展现出较好的性能。这表明我们的噪声筛选策略和特征提取方法在大规模数据集上的有效性, 能够帮助模型在复杂数据环境中维持较高的准确性。

4. 对比分析

为了更全面地评估我们的方法，我们将其与几种常见的基准模型进行了对比，结果如下：

方法	WebFG-400 准确率(%)	WebiNat-5000 准确率(%)
ResNet-50	65.8	58.2
EfficientNet-B4	67.1	59.6
ConvNeXt Base (我们的 方法)	69.3	60.9

模型对比：与 ResNet-50 和 EfficientNet-B4 等基准模型相比，我们的 ConvNeXt 模型在两个数据集上的表现均有所提升。尤其是在 WebFG-400 数据集上，ConvNeXt 相较于 ResNet-50 的提升幅度较大，证明了该模型在细粒度图像识别任务中的优势。

噪声鲁棒性：我们的模型在面对噪声数据时能够保持较好的准确性，特别是在类别内差异小、标签噪声较多的情况下，ConvNeXt 模型能够更好地捕捉到细粒度特征，从而有效提升分类性能。

5. 实验挑战与优化

在实验过程中，我们面临了多个挑战：

标签噪声与数据不均衡：WebFG-400 和 WebiNat-5000 数据集的标签噪声和数据不均衡问题，导致传统模型容易过拟合噪声。通过我们的噪声筛选和数据清洗策略，成功地减少了这些问题的影响。

长尾分布：在 WebiNat-5000 数据集上，部分类别的样本数量较少，这使得模型在这些类别上的表现较差。为了应对这一问题，我们采用了自监督学习和数据增强技术，提升了模型在长尾类别上的鲁棒性。

计算资源与优化：大规模数据集的训练需要大量计算资源，特别是在特征提取和模型训练阶段。为了提高计算效率，我们利用了分布式训练和 GPU 加速技术，显著缩短了训练时间。

4 获奖和组员分工说明

本项目在 2025 年第七屆全球校园人工智能算法精英大赛省级选拔赛中表现出色，最终获得了二等奖。我们通过对网络监督细粒度图像识别

任务的创新性算法设计和优化，成功克服了标签噪声、数据偏差和细粒度类别间差异小等挑战，获得了评审专家的高度评价。

比赛成绩与评审：

赛道名称：算法挑战赛

赛题名称：网络监督细粒度图像识别

组员：刘润章、徐瀚章、南怡波

最终成绩：二等奖

组员分工说明：

本项目的成功离不开每位组员的共同努力与协作，团队成员各自承担了不同的任务，在项目的各个阶段发挥了重要作用。以下是每位组员的具体分工和贡献：

刘润章

主要职责：负责项目的整体设计与算法优化，领导团队解决细粒度图像识别中的核心技术难题。

贡献：

算法设计：负责设计和优化整个算法框架，包括数据清洗、特征提取、噪声筛选等关键部分。通过对网络数据中的标签噪声和长尾数据问题的深入分析，提出了基于相似度的噪声筛选方法，显著提高了模型的鲁棒性和准确性。

特征提取优化：主导特征提取阶段，选择并微调了预训练的 ConvNeXt 模型，使得提取的图像特征能够更好地适应细粒度分类任务。

模型调优：负责模型的超参数调优和训练策略的优化，通过结合数据增强、正则化和学习率调度策略，提升了模型的性能和训练稳定性。

徐瀚章

主要职责：负责数据预处理、特征选择以及模型评估工作。

贡献：

数据预处理：参与了数据清洗阶段的工作，协助编写和执行 `1_clean_minimal.py` 脚本，确保数据集中的噪声图像被及时剔除，保证了数据质量。

特征选择与评估：在特征提取阶段，帮助确定了用于分类的最优特征，并参与了模型在不同数据集上的测试与评估，确保模型在 WebFG-400 和 WebiNat-5000 数据集上的优异表现。

结果分析与报告撰写：负责分析实验结果，

整理和撰写实验部分的内容,确保报告中所有的实验数据和结果呈现清晰、准确。

南怡波 (Team Member)

主要职责: 负责模型训练、噪声筛选及实验数据整理。

贡献:

噪声筛选: 主导了噪声筛选阶段的工作,编写了 `3_1_score_delete.py` 脚本,成功地识别和筛选掉了疑似噪声样本,有效提高了模型在细粒度类别上的分类性能。

模型训练: 参与了模型训练过程,调试了模型训练过程中的各种参数设置,并确保训练过程中的数据输入输出的正确性。

实验数据整理: 负责整理和分析模型训练中的实验数据,并在团队中共享关键数据和指标,确保所有成员都能对实验结果进行实时跟踪。

协作与合作:

团队协作: 虽然每位组员有各自的主要任务,但在项目的每个阶段,所有成员都进行了紧密合作。例如,在噪声筛选阶段,刘润章与南怡波共同讨论了筛选标准,并在实验中调整了不同的阈值,以确保最佳的噪声去除效果。

代码整合与版本控制: 所有组员都使用 Git 进行代码管理,确保了项目中的代码能够高效协作和版本控制,避免了代码冲突和重复工作。

5 实验心得

通过本次比赛的参与与项目的实施,我们不仅深入探索了细粒度图像识别的技术挑战,也在实际操作中积累了宝贵的经验。在实验过程中,我们面临了多个挑战,特别是在处理网络监督数据中的噪声标签、类内差异小以及长尾数据问题时,通过一系列优化措施,我们逐步克服了这些难题。以下是我们在整个实验过程中总结出的主要心得:

1. 数据清洗的重要性

数据清洗在本项目中扮演了至关重要的角色。网络监督数据集中的噪声标签和低质量图像严重影响了模型的训练效果。通过有效的数据清洗策略,我们能够显著提高数据质量,从而避免了训练过程中的许多潜在问题。例如,清洗过程

中剔除的损坏图像、透明背景图像和尺寸过小的图像,减少了模型在训练时出现错误或计算上的困难。这一阶段的工作虽然耗时较长,但为后续的特征提取和训练提供了更为干净和高质量的数据基础。

2. 特征提取与预训练模型的优势

在特征提取阶段,我们发现利用预训练的模型(如 ConvNeXt)进行特征提取,能够有效地利用已有的大规模数据集(如 ImageNet)中学到的知识,从而获得具有较强泛化能力的特征表示。通过微调预训练模型,我们能够在细粒度图像分类任务中获得明显的性能提升。这一发现也进一步验证了迁移学习的有效性,尤其是在数据量有限且标签噪声较大的情况下,预训练模型为我们的算法提供了极大的帮助。

3. 噪声筛选策略的有效性

噪声标签是网络监督学习中的一个核心挑战。在本项目中,我们设计了一种基于相似度的噪声筛选方法,通过计算类内图像之间的相似度,剔除了那些与其他样本差异较大的噪声样本。实验结果表明,这一策略显著提高了模型的鲁棒性和准确性,尤其是在面对 WebiNat-5000 这样大规模、长尾分布的数据集时。通过对不同类别样本的相似度评分,我们能够有效减少过拟合,并提升模型在细粒度分类任务中的表现。

4. 长尾数据问题与自监督学习

在 WebiNat-5000 数据集上,我们遇到了长尾数据问题,即某些类别的样本数量过少,导致模型在这些类别上的表现较差。为了解决这个问题,我们尝试了自监督学习方法。自监督学习帮助我们在缺乏足够标注数据的情况下,通过自动学习图像的内在结构和特征,进一步提升了模型在长尾类别上的表现。这一策略有效增强了模型在多样化数据集上的适应能力。

5. 模型训练的挑战与优化

在模型训练过程中,我们发现数据的高质量 and 模型架构的优化同样重要。即便是在细粒度图像识别这样复杂的任务中,适当的模型调优和超参数设置能够帮助我们进一步提高模型的准确性。在训练过程中,使用了学习率调度(如 Cosine

Annealing) 和数据增强 (如随机裁剪、翻转) 等策略, 帮助我们提高了训练效率, 减少了模型的过拟合问题。

6. 计算资源的利用

大规模数据集的训练需要大量的计算资源。我们在实验中充分利用了 GPU 加速和分布式训练技术, 显著提高了训练速度, 并减少了模型训练时间。这对于处理像 WebiNat-5000 这样规模庞大的数据集来说至关重要。在这一过程中, 优化计算资源的使用, 合理选择批次大小和并行处理方法, 有助于加快训练进程并提高实验的效率。